基于R语言的爬虫和基本文本分析

目录

1　基本任务描述

随着大数据时代的到来，互联网上产生了越来越多的数据具有很大的参考价值，这些数据中往往蕴含着充分的政治、经济、社会人文等各种充满价值的信息，如果充分利用互联网信息来解读社会发展脉络，提炼其背后所蕴含的信息意义重大。本文的任务是通过爬虫技术获取网页数据，然后对获取的数据进行数据清洗，数据处理相关工作，然后对该数据进行基本的统计分析，以获得数据中所获得的有价值的信息。此次获取的是上海对外经贸大学活跃度较高、在同学之间名气较为旺盛的微信公众号——大猫助手pro的网页评论，该评论由于是非官方平台且采用匿名制，较能反映出大学生内的真实想法，具有较强的舆情价值。

2　设计思路

本文通过R语言中的爬虫程序来获取和解析网页内容，本文在线抓取了自3月份至6月份一共70天的数据，获得1453条学生评论，然后通过jieba对每条内容进行分词，由于平日用语中的类似助词等的词汇，但是这些词汇我们并不感兴趣，所以通过载入停用词表（可以在附录中网址获得），去除这些停用词，然后就可以对文本进行基本的统计，获取出现评率最高的词汇。频率最高的词汇并不一定是最重要的词汇，此时引入逆文档频率的相关概念，然后得到更为重要的关键词，通过绘制词云获得可视化效果，以此来推断该群体的状况与舆论态势，可以进行很多工作。设计的流程图如图1所示。

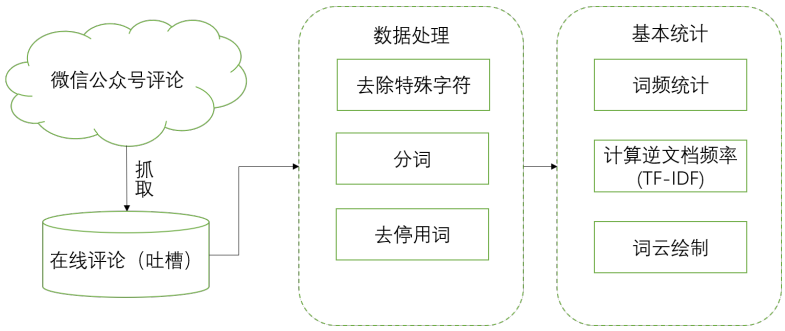

图 1: 设计流程图

3　文本获取

爬虫的基本原理是模拟浏览器发送请求,然后下载网页代码（本文所使用的网页的URL可的网址下载获取），R语言有丰富的包可以实现获取网页代码，本文采取的是rvest包来获取，然后利用RCurl包中的html_nodes 函数来提取网页中有用的内容，由于评论较为简短，所以在附录中以把每一条评论存放在一个数据框中

4　文本处理

4.1　去除特殊字符与分词

到目前为止我们所获取的还是整句的评论，想要进一步分析评论所蕴含的信息，我们要对评论进行分词处理。注意到评论中含有的表情符号解析后是由特殊字符和数字构成的，这对分词结果会造成影响，所以我们应该首先除去这些特殊字符，这里本文采用的是通过正则提取的方式去除这些特殊字符。而后对每一条评论进行分词。分词所采用的工具是R语言中的jiebaR库来实现，jiebaR库一共提供7种分词引擎，在本文中采取的是混合模型。它混合使用了最大概率法和隐式马尔科夫模型，是目前分词较为准确的一种。对所有评论分词之后一共获取29383个词汇，部分结果显示如图2所示。

```
> wordsLib
  [1] "宿舍"     "打"       "守望"     "跳"       "ping"     "也"       "太"
  [8] "严重"     "了吧"     "开"       "热点"     "也"       "这样"     "是不是"
 [15] "应该"     "去"       "插个"     "网线"     "打游戏"   "顺畅"     "的"
 [22] "兄弟"     "们"       "有"       "什么"     "办法"     "吗"       "QAQ"
 [29] "xdm"      "别钓"     "了"       "蛮"       "难过"     "的"       "喜欢"
 [36] "了"       "好久"     "的"       "人"       "因为"     "怕"       "失去"
 [43] "不敢"     "问"       "她"       "性"       "向"       "自我安慰" "看"
```

图 2: 部分分词结果

4.2 去停用词与非中文词

从分词结果中我们可以看到类似“了”、“的”之类的助词对我们进行文本分析是没有帮助的，所以我们必须去除这些对于文章内容理解无关紧要的词汇，本文通过载入停用词表的方式对分词之后的文本进行匹配（本文所使用停用词表可以在附录网页中下载获取）如果文本中出现在停用词表中，则去除这些词汇，通过去停用词之后，剩下16779个关键词汇。部分结果显示如图3所示。

```
> cleanWords
  [1] "宿舍"     "守望"     "跳"       "ping"     "严重"     "了吧"     "开"
  [8] "热点"     "是不是"   "应该"     "插个"     "网线"     "打游戏"   "顺畅"
 [15] "兄弟"     "办法"     "QAQ"      "xdm"      "别钓"     "蛮"       "难过"
 [22] "喜欢"     "好久"     "怕"       "失去"     "不敢"     "问"       "性"
 [29] "自我安慰" "朋友"     "今天"     "讲"       "谈恋爱"   "女孩子"   "难过"
 [36] "空落落"   "胆小鬼"   "考研"     "高考"     "更"       "难吗"     "好奇"
 [43] "名校"     "情结"     "考研"     "更难"     "复读"     "好奇"     "所有人"
```

图 3: 去停用词后结果

从分词结果可以看出，分词对结果有较大影响，对更准确把握文本内容具有重大意义。

4.3 词性标注

到目前为止已经完成了关键词的提取，我们还可以对关键词的进行词性标注，加深对文本内容的把握。对这一目标的实现使用了R语言的tmcn库中的vector_tag函数，可以实现对每个词的词性标注，截取频率前十的词性绘制条形图，结果如图4(a)所示

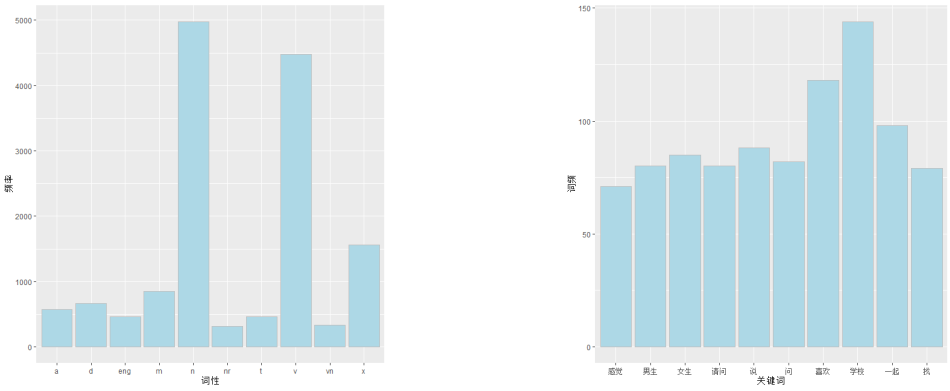

(a) 词性统计　　(b) 词频统计

图 4: 基本统计

5 基本统计

5.1 词频统计

完成了对文本的预处理工作之后，我们需要进行处理后的内容进行基本的统计，首先

是对词频的统计，经过去停用词之后选取频率前十的词语绘制条形图，结果如图4(b)所示。为了获得更好的可视化效果，选取频率前50的词语，绘制词云图，结果如图5所示。

图 5: 词云图

5.2 计算关键词重要性TF-IDF

前面所作的工作都是为了提取每个词语的频率，但是词语出现的频率越高，不一定代表该词越重要，相反的是在一些特殊的文章中，某些词语虽然频率在这篇文档中不是最高的，但是在其他文档中比较少见，说明这种词汇反映了该文章的特性，为了描述这种现象，引入逆文档频率的概念。

在词频(Term Frequency)基础之上，设置一个重要性调整系数，对较少见的词给予较大的权重，即逆文档频率(Inverse Document Frequency)简称IDF，而后提出关键词重要性(TF-IDF)，是由词频和逆文档频率的乘积定义，用这个指标提取文本中的关键词。为了便于解释，特对符号进行说明，如表1所示。

属性	符号
词汇频率	TF
逆文档频率	IDF
语料库的文档总数	sumCorpus
包含该词的文档数	incCorpus
关键词重要性	IF-IDF

表 1: 符号说明

逆文档频率的计算方法为

$$IDF = log(\frac{sumCorpus}{invCorpus+1})$$

关键词重要性的计算方法为

$$TF-IDF = TF \times IDF$$

本文所采用的语料库是jiebaR库中所带有的语料库，经过计算之后，提取重要性前二十的词汇绘制条形图，如图6所示。

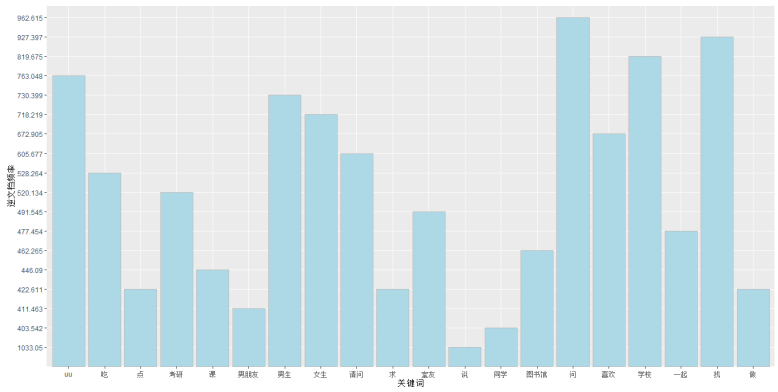

图 6: 逆文档频率

6 结果分析

由于所抓取网页的特殊性（该公众号以匿名表白而在同学之间闻名），所获取的数据本身带有一定的情感倾向，通过对文本进行基本的统计之后，发现文本内容多以情感类词汇为主，比如“喜欢”、“男朋友”、“女生”等，说明所获得的结果能够和实际情况充分印证。

7 自我评价

本文完成了最基本的网页数据的处理分析工作，但是获取数据之后对数据利用率太低，只是进行了最基本的统计，没有进一步挖掘数据背后所蕴含的信息，下一步可以对数据进行主题分析，情感分析等实现对所获取数据的高效率利用。

参考文献

[1]轻松学统计，基于R语言的TF-IDF算法（文本挖掘），http://blog.csdn.net/kunga0814/archive/2009/04/22/4099829.aspx，6(8),2021
[2]R语言中文社区，R语言自然语言处理：关键词提取（TF-IDF），https://blog.csdn.net/kMD8d5R/article/details/88564616，(6)8,2021
[3]R3eE9y2OeFcU40，R语言自然语言处理：词性标注与命名实体识别，https://blog.csdn.net/R3eE9y2OeFcU40/article/details/88265401，6(8),2021
[4]余醉 — dtminer，R语言数据可视化词云绘制，https://blog.csdn.net/sinat_30361015/article/details/85876695，6(8),2021

A 附录

A.1 代码

```
1
2 library(tmcn)
3 library("HMM")
4 library(rvest)
5 library(RCurlibrary(openxlsx)  # read excel file
6 library(jiebaRD)
7 library("jiebaR")
8 library(NLP)
```

```
library(tm)
library(RColorBrewer)
library(wordcloud2) # word cloud
library("topicmodels")
library("Rwordseg")
library("ggplot2")
library(tidyverse)  # offer enframe to transform the type of data
library(magrittr)

setwd("d:/Rdata/Crawl")

# Loading data
urlData<-read.xlsx('url.xlsx')

urlData <- as.matrix(urlData)

urlData <- urlData[1:70]

htmlData1 <- matrix()

for (turl in urlData){

        if(url.exists(url=turl)){

                hdata<-read_html(turl)

                htmlData<-hdata%>%html_nodes('div.rich_media_content section
        section section section section section
        section section')%>%html_text()

                htmlData <- as.matrix(htmlData)

                htmlData1 = rbind(htmlData,htmlData1)
        }
}

na.omit(htmlData1)

wk = worker()

wordsLib <- c()

textLib <- data.frame()

for(i in htmlData1){

        tmp <- wk[i][grep("[^0-9]",wk[i],fixed=FALSE)]

        textLib <- rbind(textLib)

        wordsLib <- c(wordsLib,tmp)
}

na.omit(wordsLib)

```

```
64
65 stopwords <- unlist(read.table("StopWords.txt",encoding = "utf-8",
66 fileEncoding = "utf-8"))
67
68 removeStopWords <- function(x,stopwords) {
69
70         temp <- character(0)
71
72         index <- 1
73
74         xLen <- length(x)
75
76         while (index <= xLen) {
77
78                 if (length(stopwords[stopwords==x[index]]) <1)
79
80                 temp<- c(temp,x[index])
81
82                 index <- index +1
83
84         }
85
86         return(temp)
87
88 }
89
90 cleanWords <-lapply(wordsLib,removeStopWords,stopwords)
91
92 cleanWords <- as.character(cleanWords)
93
94 temp <- cleanWords
95
96 temp <- which(temp == "character(0)")
97
98 cleanWords <-cleanWords[-temp]
99
100 freSta <- freq(cleanWords)
101
102 tag_worker = worker(type = "tag")
103
104 wordType <- vector_tag(cleanWords,tag_worker)
105
106 typeFre <- freq(wordType)
107
108
109
110 f <- typeFre[order(typeFre[2], decreasing = TRUE),]
111
112 ggplot(f[1:10,], aes(x=char,y= freq))+xlab("␣Key␣Words")
113 +ylab("Frequency␣of␣Words") + geom_bar(
114 stat="identity",fill="lightblue", colour="grey")
115
116 f2 <- f[1:50,]
117 wordcloud2(data=f2,size = 1,minSize = 0.5,gridSize = 0,
118 backgroundColor = "white",color = "random-dark",minRotation = -pi/4,
```

```
maxRotation=pi/4,rotateRatio=0.4, shape='circle',ellipticity=0.65,
widgetsize=NULL)

f3 <- f[1:15,]
ggplot(f3, aes(x=char,y= freq)) + geom_bar(stat="identity",
fill="lightblue", colour="grey")


enframe(wordType) -> tag_table

speechPart <- freq(tag_table$name)

speechPart <- speechPart [order(speechPart $freq,decreasing = TRUE),]

ggplot(speechPart[1:10,], aes(x=char,y= freq))+xlab("Word type")+ylab(
"Frequcncy") + geom_bar(stat="identity",fill="lightblue", colour="grey")


keys = worker("keywords",topn = 20)

x <- vector_keywords(wordType,keys)

y <- enframe(x)

ggplot(y, aes(x=value,y= name))+xlab("Key Word")+ylab(
"the value of TF-IDF") + geom_bar(stat="identity",
fill="lightblue", colour="grey")
```

A.2 数据

本文所需数据可从以下网址获取
https://github.com/Guanghui-hua/Rcode